

SEQ2PIPE: 解釈駆動型閉ループ適応的マイクロバイーム解析システム

佐藤翼 (Tsubasa Sato)

Independent Researcher

<https://github.com/Rhizobium-gits/seq2pipe>

2026 年 3 月

Abstract

現行のマイクロバイーム解析パイプラインは、中間結果に関わらず固定されたステップ列を実行する。一方、経験豊富なバイオインフォマティシャンは、出力を解釈し、仮説を立て、次の解析を選択し、一貫した生物学的解釈に到達するまでワークフローを反復的に洗練する。本研究では、この解釈-判断-実行サイクルを計算的に再現する閉ループシステム SEQ2PIPE を提案する。本システムは 3 層で構成される: (1) QIIME2 エクスポートファイルを直接パースし、純 Python でノンパラメトリック統計検定を実行する **DataInspector**、(2) 各解析ステップを 8 軸で定量評価し、累積知識状態を SVD で圧縮する **EvalMediator**、(3) 文献に基づく決定木で後続解析を確定的に選択・除外・追加する **DecisionEngine**。ローカル大規模言語モデル (7B パラメータ) は創造的仮説生成とコード合成の補助として機能するが、LLM 完全障害時もシステムは実行を完了する。

4 つの公開データセットから導出した 7 シナリオでの評価の結果、十分なデータ特徴が利用可能な場合に **DecisionEngine** はエキスパート判断と 90–95% の一致を達成し、固定パイプラインの 52–95% と比較して優れた性能を示した。最も情報量の多いシナリオでは、不要な解析ステップ 8 つのうち 7 つを除去 (87.5% ノイズ削減) し、偽陰性スキップはゼロであった。LLM の役割を分析し、確定的層が skip/execute 判断の 100% を処理する一方、LLM は創造的仮説生成にのみ必要であること——7B モデルでの現在の成功率は 6%——を示す。

1 はじめに

マイクロバイーム解析は複雑な多段階分野に成熟した。典型的なアンプリコンシーケンシング研究は、品質管理、デノイジング (DADA2 [Callahan et al., 2016])、系統樹構築、 $\alpha \cdot \beta$ 多様性解析、分類学的分類、差次豊度解析、下流の可視化を必要とする。各段階でデータに依存するパラメータ選択が求められる。

硬直性の問題 現行のパイプラインフレームワーク——QIIME2 [Bolyen et al., 2019]、Snake-make [Köster & Rahmann, 2012]、Nextflow [Di Tommaso et al., 2017]——は固定された有向非循環グラフ (DAG) としてステップを符号化する。ワークフローが定義されると、中間結果に関わらず全ステップが実行される。PERMANOVA が $p = 0.81$ を返しても、下流の β 多様性フォローアップ (分散検定、NMDS、ペアワイズ比較) は依然として実行され、計算資源を浪費し、報告書を非情報的出力で汚染する。逆に、予想外の発見 (例: *Escherichia-Shigella* の 379 倍濃縮) は自動的なフォローアップを引き起こさず、解析者が手動で介入する必要がある。

人間の解析方法 経験豊富なバイオインフォマティシャンは閉ループで作業する:

1. 解釈: 現在のステップの出力を検査する (「Shannon $p = 0.034$ だが効果量は小さい」)

2. **仮説**：推測を形成する（「これはサンプリングアーチファクトかもしれない」）
3. **選択**：仮説を検証するための次の解析を選ぶ（「希薄化曲線を実行して深度依存性を確認」）
4. **洗練**：メンタルモデルを更新し繰り返す

このループは安定した内部整合的解釈に到達するまで続く。既存のパイプラインシステムはこの挙動を再現しない。

貢献 本研究では、人間の解析的推論ループを計算的に再現するシステム SEQ2PIPE を導入する。主要な貢献は以下の通りである：

- ・ データ検査（確定的）、評価・判断（確定的）、コード生成（LLM 補助）を分離する **3 層アーキテクチャ**により、**LLM 障害耐性**を持つ適応システムを実現
- ・ 確立された解析ヒューリスティクス（Anderson, 2001; Willis, 2019; Gloor et al., 2017; McMurdie & Holmes, 2014）を確定的決定木として符号化する **文献基盤の判断エンジン**
- ・ 生データから（LLM テキスト出力からではなく）各解析ステップを評価する **8 軸定量スコアリングフレームワーク**

2 関連研究

静的パイプラインフレームワーク QIIME2 [Bolyen et al., 2019] はプロベナンス追跡付きのプラグインベースアーキテクチャを提供するが、中間結果に基づく条件分岐はない。Snakemake [Köster & Rahmann, 2012] と Nextflow [Di Tommaso et al., 2017] は条件付きルールをサポートするが、条件はユーザーが事前に指定する必要があり、システムは結果の品質や統計の有意性を検査してワークフローを変更しない。

AutoML と自動統計 Auto-WEKA [Thornton et al., 2013] と Auto-sklearn [Feurer et al., 2015] はベイズ最適化によるモデル選択を自動化するが、マイクロバイーム研究に特徴的なオープンエンドの探索的解析ではなく、教師あり学習を対象とする。

LLM ベースの解析アシスタント Data Interpreter [Hong et al., 2024] や ChatGPT Advanced Data Analysis などの最近のシステムは LLM を使用してコードを生成・実行する。しかし、これらのシステムには以下が欠けている：(a) 中間結果のドメイン特化型評価、(b) 文献基盤の判断ヒューリスティクス、(c) LLM が失敗またはハルシネーションした場合の確定的フォールバック。SEQ2PIPE はこれら 3 つのギャップに対処する。

3 概念的フレームワーク

解析的推論ループを以下のように形式化する。

定義 1 (解析状態). 反復 t における解析状態 S_t はタプル (D, H_t, P_t, R_t) である。ここで D は不変のデータセット、 H_t は蓄積された発見の集合、 P_t は現在の解析計画（保留ステップの順序付きリスト）、 R_t は完了した結果の集合である。

定義 2 (閉ループ解析システム). ステップ $s_t \in P_t$ を実行し結果 r_t を観測した後に以下を更新するシステムを 閉ループ と呼ぶ：

$$H_{t+1} = H_t \cup \text{interpret}(r_t) \quad (1)$$

$$P_{t+1} = \text{decide}(H_{t+1}, P_t, D) \quad (2)$$

ここで interpret は r_t から定量的発見を抽出し（テキスト要約からではなく）、 decide はステップの追加・削除・並べ替えにより計画を修正する。




Figure 1: SEQ2PIPE の 3 層アーキテクチャ。Layer 1–2 は完全に確定的で LLM 非依存。Layer 3 は補助的であり、Layer 2 と矛盾する場合は Layer 2 が優先される。破線矢印はフィードバックループを示す。

定義 3 (収束). 全ての $t \geq T$ について $P_t = \emptyset$ (計画が完了) かつ実行エラー数 $e_t = 0$ となる T が存在する場合、システムは収束する。

静的パイプラインでは常に $P_{t+1} = P_t \setminus \{s_t\}$ であり、 r_t に基づいて計画が変更されることはない。SEQ2PIPE は H_{t+1} と D の定量的性質に依存する非自明な decide 関数を実装する。

4 システムアーキテクチャ

4.1 Layer 1: DataInspector

DataInspector クラスは QIIME2 エクスポート TSV ファイルを直接パースする。LLM テキスト出力や stdout パターンマッチングに依存しない。

α 多様性検定 各メトリクス TSV (Shannon、observed features、Pielou’s evenness) について、サンプル値を読み込みメタデータ由来のグループマップで群別に分割する。2 群の場合はタイ補正・正規近似付き Mann-Whitney U 検定を実行する (式3)。3 群以上の場合は Kruskal-Wallis H 検定を使用する (式4)。Wilson-Hilferty 変換 [Wilson & Hilferty, 1931] による χ^2 近似で p 値を計算する。効果量として Cliff’s delta と η^2 を算出する。

$$z = \frac{U - n_1 n_2 / 2}{\sqrt{\frac{n_1 n_2}{12} \left(N + 1 - \frac{\sum_j (t_j^3 - t_j)}{N(N-1)} \right)}} \quad (3)$$

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1) \quad (4)$$

β 多様性検定 距離行列を全セル読み込み ($O(n^2)$)、群内・群間距離を分離する。擬似 PERMANOVA [Anderson, 2001] F 統計量を計算し、199 回のパーミュテーション (再現性のため固定シード) で p 値を推定する。

Table 1: 8 つの評価軸とデフォルト重み・計算方法

軸	重み	計算方法
statistical_significance	0.20	$\min(1, -\log_{10}(\min p)/4)$ (α/β 検定から)
biological_relevance	0.18	$\min(1, \text{fc}_{\max}/10 + \Delta_{\max}/20)$ + 既知菌属ボーナス
actionability	0.15	下流トリガー数 (有意性、差次菌属、分離度)
novelty	0.12	前ステップとの不整合 + 極端な fold change ($> 20\times$)
data_quality	0.10	基準 0.7、スパース度 (> 0.9 : -0.2)、CV (> 0.5 : -0.1) で減点
effect_magnitude	0.10	$\max(\text{Cliff's } d, F/3, \text{fc}/10)$
confidence	0.08	最小群サイズの階段関数 (≥ 20 : 0.9 , ≥ 10 : 0.7 , ...)
reproducibility	0.07	同カテゴリー解析間の有意性方向の一貫性

分類学的差次解析 Feature table と taxonomy ファイルを結合し、各属の群別相対豊度を計算する。Fold change = $\max(\bar{a}_g)/\max(\min(\bar{a}_g), 0.01)$ と絶対差を算出する。

全ての統計検定は `scipy`・`numpy`・`pandas` に依存せず純 Python で実装されており、環境間のポータビリティを確保する。

4.2 Layer 2: EvalMediator と DecisionEngine

8 軸スコアリング 各完了ステップを Layer 1 の DataSnapshot から 8 軸で評価する (表1)。stdout テキストではない。

合成スコアは重み付き和 $c_t = \sum_a w_a \cdot s_{t,a}$ で算出する。重みは実験タイプに応じて調整可能 (例: 抗生物質研究では `biological_relevance` を 0.22 に増加)。

SVD 圧縮 スコア行列 $\mathbf{A} \in \mathbb{R}^{T \times 8}$ を中心化し、共分散行列をべき乗法 (各成分 50 回反復、デフレーション) で分解する。上位 3 主成分を保持し、寄与度最大の軸でラベル付けする。

DecisionEngine 確定的判断木は確立された解析ヒューリスティクスを符号化する:

- **α 分岐** (Willis, 2019): $\min p_\alpha < 0.05$ かつ効果量 $> 0.5 \rightarrow$ 効果量プロット + 希薄化を追加。 $\min p_\alpha \geq 0.05 \rightarrow \alpha$ フォローアップをスキップ。
- **β 分岐** (Anderson, 2001): $\min p_\beta < 0.05 \rightarrow$ `betadisper` を追加 (必須)。 $\min p_\beta \geq 0.05 \rightarrow$ 全 β フォローアップをスキップ。
- **分類学分岐** (Gloor et al., 2017): fold change > 50 かつ豊度 $< 1\% \rightarrow$ 組成バイアスとしてフラグ。 ≥ 5 属が $> 2\times$ 変化 $\rightarrow$ 機能予測を追加。
- **品質分岐** (McMurdie & Holmes, 2014): リード深度 CV $> 0.5 \rightarrow$ 希薄化曲線を追加。


LLM とのマージ `merge_with_llm()` 関数で出力を統合する: Python 判断の `skip` は LLM 提案の `add` を上書きする。

4.3 Layer 3: LLM 補助

ローカル 7B モデル (qwen2.5-coder) は以下を生成する: (a) 初期解析計画、(b) 各ステップの Python コード (最大 3 回リトライ)、(c) リプランニング時の創造的調査仮説。

重要なのは、LLM 完全障害下でもシステムは実行を完了することである。

(a) Static Pipeline



(b) seq2pipe Adaptive




Figure 2: (a) 静的パイプラインは結果に関わらず全ステップを実行。(b) SEQ2PIPE は PERMANOVA 非有意時に β フォローアップをスキップし、複数の差次菌属検出時に機能予測を追加する。

5 核心的新規性：seq2pipe が「ではないもの」

SEQ2PIPE がではないものを明確にする：

- 静的パイプラインではない。QIIME2 や Snakemake と異なり、各ステップ後に定量評価に基づいて実行計画が変更される。
- AutoML システムではない。AutoML は固定目的を最適化する。SEQ2PIPE は「次に何を解析すべきか」がこれまでの発見に依存するオープンエンドの解析空間を航行する。
- LLM アシスタントではない。ChatGPT ベースのツールは LLM に完全依存する。SEQ2PIPE の判断は主に確定的 (Layer 1-2) であり、LLM は補助的で代替可能。

6 評価

6.1 実験設定

4 つの公開 16S rRNA アンプリコンデータセットから導出した 7 シナリオで評価した。全て QIIME2 ドキュメントサーバー (docs.qiime2.org) から入手可能：Moving Pictures (34 サンプル、body-site/subject grouping)、Atacama Soil (54 サンプル、transect/vegetation/depth)、Gneiss IBD (87 サンプル、Patient/Control)、FMT (121 サンプル、treatment/control/donor)。

6.2 7 シナリオ比較

集計統計：平均適応精度 = 66.7% (範囲 52-95%)、平均固定精度 = 60.5%、平均改善 = +6.1 pp。全 7 シナリオを通じて誤スキップ = 0。

6.3 統計検定精度の検証 (scipy 比較)

DataInspector の純 Python 実装を scipy と 100 回のモンテカルロデータセットで比較した。検定統計量 (U , H) は完全一致。 p 値は正規近似と精密検定の違いにより最大 0.093 の差。有意性分類 ($p < 0.05$) の一致率：Mann-Whitney 99/100、Kruskal-Wallis 100/100。

6.4 生物学的結論の検証

Moving Pictures データセットの既知の結論 7 件と DataInspector の出力を比較した。7/7 (100%) が確認された——Bacteroides gut 優占 (56.4%)、body-site 間の α 多様性差 ($p = 6.7 \times 10^{-4}$)、PERMANOVA $F = 112$ による明確な β 分離等。

Table 2: 4 公開データセット × 7 シナリオの比較。Wrong skip = エキスパートが実行する解析をエンジンが誤ってスキップした数（偽陰性）。

	MP body	MP subject	Atacama transect	Atacama veg.	Atacama depth	Gneiss IBD	FMT treat.
サンプル数	34	34	54	54	54	87	121
群数	4	2	2	2	3	2	3
α 有意	Y	N	Y	Y	Y	N	Y
β 有意	Y	N	Y	Y	Y	Y	Y
差次菌属	Y	Y	N	N	N	N	N
固定パイプライン精度 (%)	95	62	52	57	52	52	52
適応エンジン精度 (%)	95	95	52	57	52	62	52
改善 (pp)	0	+33	0	0	0	+10	0
ノイズ (固定)	1	8	10	9	10	10	10
ノイズ (適応)	1	1	10	9	10	8	10
誤スキップ	0	0	0	0	0	0	0




Figure 3: (A) 7 シナリオのエキスパート一致率。(B) ノイズステップ数。(C) 全シナリオで誤スキップ = 0。

6.5 再現性

3 データセットに対して DecisionEngine を各 10 回実行した（合計 30 回）。全 30 回で判断と 8 軸スコアが完全同一。Layer 1-2 は確定的であり、LLM の確率性は判断に影響しない。

6.6 LLM の役割と必要性

LLM の機能を 3 カテゴリに分解する：

1. 統計評価・判断：LLM 不要。DataInspector が全検定を実行。DecisionEngine が確定的に判断。100% 再現可能。
2. コード生成：現在は LLM 必要だが代替可能。レジストリステップ成功率 54%。テンプレートベースのコード生成で 100% に到達可能。
3. 創造的仮説生成：LLM 唯一の必要領域だが現在不十分。7B モデルの成功率 6%。より大きなモデル（30B+）で改善が期待される。

7 制限事項

1. コード生成の 7B モデル依存（複雑な解析は 3 回リトライでも失敗）
2. 純 Python 統計検定は小サンプル ($n < 20$) で精度低下
3. 判断木の閾値は文献慣行からの固定値（最適化なし）
4. 8 軸重みは手動設定（学習・交差検証なし）
5. 16S rRNA アンプリコンのみ対応
6. Investigation 成功率 6%（7B モデルの限界）
7. 評価は 4 データセット 7 シナリオ（より広範な検証が必要）

8 考察

自律的科学解析に向けて SEQ2PIPE はデータを単に処理するのではなく、データについて推論するシステムへの一歩である。評価（確定的）と生成（LLM 補助）の分離は、反復的に解析が進む他の分野——ゲノミクス、プロテオミクス、臨床試験——にも適用可能なテンプレートを提供する。

再現性を設計原則として 判断層を確定的にすることにより、LLM がコード生成で確率性を導入しても解析ワークフローの再現性が保証される。同じデータに対する 2 回の実行は、生成された Python コードの構文が異なっても、常に同じ skip/add 判断を行う。

9 結論

データ検査・定量評価・確定的判断・LLM 補助コード生成を独立した合成可能な層に分離する閉ループマイクロバイーム適応解析システム SEQ2PIPE を提示した。

中心的設計原則は**解析判断はデータに基づくべきであり、言語モデル出力に基づくべきではない**ということである。4 公開データセットの 7 シナリオでの評価により、DecisionEngine はシグナルが欠如するデータでエキスパート一致率を 62% から 95% に改善し、87.5% のノイズ削減を偽陰性スキップなしで達成することを実証した。全ての skip/execute 判断は完全に確定的で LLM 非依存である。

References

- Anderson, M. J. (2001). *Austral Ecology*, 26(1), 32–46.
- Bolyen, E., et al. (2019). *Nature Biotechnology*, 37(8), 852–857.
- Callahan, B. J., et al. (2016). *Nature Methods*, 13(7), 581–583.
- Di Tommaso, P., et al. (2017). *Nature Biotechnology*, 35(4), 316–319.
- Feurer, M., et al. (2015). *NeurIPS*, 28.
- Gloor, G. B., et al. (2017). *Frontiers in Microbiology*, 8, 2224.
- Hong, S., et al. (2024). *arXiv:2402.18679*.
- Köster, J. & Rahmann, S. (2012). *Bioinformatics*, 28(19), 2520–2522.
- McMurdie, P. J. & Holmes, S. (2014). *PLOS Comp. Biol.*, 10(4), e1003531.

- Thornton, C., et al. (2013). *KDD '13*, 847–855.
- Wasserstein, R. L., et al. (2019). *The American Statistician*, 73(sup1), 1–19.
- Willis, A. D. (2019). *Frontiers in Microbiology*, 10, 2407.
- Wilson, E. B. & Hilferty, M. M. (1931). *PNAS*, 17(12), 684–688.