

SEQ2PIPE: 解釈駆動型閉ループ適応的マイクロバイーム解析システム

佐藤翼 (Tsubasa Sato)

Independent Researcher

<https://github.com/Rhizobium-gits/seq2pipe>

2026 年 3 月

Abstract

現行のマイクロバイーム解析パイプラインは中間結果に関わらず固定されたステップ列を実行し、予想外のパターンや期待シグナルの欠如に対してエキスパートの介入を必要とする。本研究では、バイオインフォマティクスの反復的な解釈-判断-実行サイクルを計算的に再現する閉ループシステム SEQ2PIPE を提案する。本システムは 3 層で構成される: QIIME2 エクスポートを直接パースし純 Python で統計検定を実行する DataInspector、各ステップを 8 軸で定量評価する EvalMediator、文献に基づく決定木で解析計画を確定的に修正する DecisionEngine。ローカル大規模言語モデル (7B パラメータ) は各解析ステップの Python コード生成および創造的調査仮説の提案を担う。LLM はコード生成に不可欠であるが (現時点で確定的代替は未実装)、全てのワークフロー判断——どのステップをスキップ・追加・並べ替えるか——は DecisionEngine が LLM の関与なしに確定的に決定する。LLM 完全障害時、判断ループは正しく動作し続けるが、個々の解析ステップは実行できない。

4 つの公開 16S rRNA データセットから導出した 7 シナリオで評価した結果、完全なデータ特徴が利用可能な場合に DecisionEngine はエキスパートプロトコルと 95% の一致を達成し、固定パイプラインの 62% と比較して 33 パーセントポイントの改善を示した。全 147 判断を通じてノイズ削減 87.5%、偽陰性スキップ = 0 であった。純 Python 統計検定は scipy との有意性分類一致率 99–100%、Moving Pictures の既知の生物学的結論 7 件全てを確認した。30 回の独立実行で判断・スコアとも完全同一であった。主要なボトルネックは 7B モデルのコード生成能力 (定義済みタスク 54%、新規調査 6%) であり、NameError (60%) と KeyError (27%) が支配的なエラーであった。

1 はじめに

マイクロバイーム解析は複雑な多段階分野に成熟し、典型的なアンプリコンシーケンシング研究は品質管理、デノイジング [Callahan et al., 2016]、系統樹構築、 $\alpha \cdot \beta$ 多様性解析、分類学的分類、差次豊度検定、および下流の可視化を必要とする。

現行のパイプラインフレームワークは固定された有向非循環グラフ (DAG) としてワークフローを符号化する。QIIME2 [Bolyen et al., 2019] はプロベナンス追跡付きのプラグインアーキテクチャを提供するが、中間結果に基づく条件分岐はない。Snakemake [Köster & Rahmann, 2012] と Nextflow [Di Tommaso et al., 2017] は条件付き規則をサポートするが、条件はユーザーが事前に指定する必要がある、統計的有意性や効果量を検査してワークフローを変更しない。その結果、PERMANOVA が $p = 0.81$ を返しても下流の β 多様性フォローア

ップは実行され、逆に *Bacteroides* の 324 倍濃縮のような予想外の発見は自動的なフォローアップを引き起こさない。

経験豊富なバイオインフォマティシャンは異なる方法で作業する：解釈、仮説形成、解析選択、洗練の閉ループで、安定した内部整合的な解釈に到達するまで継続する。既存のパイプラインシステムはこの挙動を計算的に再現しない。

本研究では、この推論ループを 3 つの確定的層とオプションの LLM に分離するシステム SEQ2PIPE を導入する。主要な貢献は以下の通りである：

1. データ検査、評価・判断（ともに確定的）、コード生成（LLM 補助）を分離し、LLM 障害耐性を持つ 3 層アーキテクチャ
2. Anderson (2001)、Willis (2019)、Gloor et al. (2017)、McMurdie & Holmes (2014) の解析ヒューリスティクスを確定的決定木として符号化する文献基盤の DecisionEngine
3. 4 公開データセット・7 シナリオでの定量的評価（エキスパート一致率 95%、偽陰性スキップ = 0、再現性 100%）

2 関連研究

2.1 静的パイプラインフレームワーク

QIIME2 [Bolyen et al., 2019] はプラグインベースのモジュール性とプロベナンス追跡を提供するが、中間結果に基づく動的なワークフロー変更はない。Snakemake [Köster & Rahmann, 2012] と Nextflow [Di Tommaso et al., 2017] は汎用ワークフロー管理を提供するが、条件は実行前にユーザーが定義する必要がある。

2.2 自動解析システム

Auto-WEKA [Thornton et al., 2013] と Auto-sklearn [Feurer et al., 2015] はベイズ最適化によるモデル選択を自動化するが、固定の目的関数を持つ教師あり学習を対象とする。マイクロバイーム解析は本質的にオープンエンドであり、「正しい」次のステップは現在のステップの発見に依存する。

2.3 LLM ベースの解析エージェント

Data Interpreter [Hong et al., 2024] や ChatGPT Advanced Data Analysis は自然言語プロンプトからコードを生成・実行する。これらのシステムは LLM に判断とコード生成の双方を完全に依存しており、(a) 中間結果のドメイン特化型定量評価、(b) 文献基盤の判断ヒューリスティクス、(c) LLM 障害時の確定的フォールバックが欠如している。SEQ2PIPE はアーキテクチャ分離によりこの 3 つのギャップに対処する。

3 概念的フレームワーク

定義 1 (解析状態). 反復 t における状態 $S_t = (D, H_t, P_t, R_t)$ は、不変のデータセット D 、蓄積された発見 H_t 、順序付き計画 P_t 、完了結果 R_t から成る。

定義 2 (閉ループ解析システム). ステップ $s_t \in P_t$ を実行し結果 r_t を観測した後に $H_{t+1} = H_t \cup \text{interpret}(r_t, D)$ 、 $P_{t+1} = \text{decide}(H_{t+1}, P_t, D)$ を更新するシステムを閉ループと呼




Figure 1: 3 層アーキテクチャ。Layer 1-2 は確定的で LLM 非依存。Layer 3 はオプション。

ぶ。interpret はデータファイルから直接定量的発見を抽出し（テキスト要約からではなく）、decide はステップの追加・削除・並べ替えにより計画を修正する。静的パイプラインでは常に $P_{t+1} = P_t \setminus \{s_t\}$ であるが、SEQ2PIPE は H_{t+1} の定量的性質に依存する非自明な decide を実装する。

4 システムアーキテクチャ

アーキテクチャ（図1）は厳格な分離を強制する：Layer 1-2 は確定的で LLM 不要、Layer 3 は確率的で代替可能。

4.1 Layer 1: DataInspector

DataInspector は QIIME2 エクスポート TSV ファイルを直接パースし、scipy・numpy・pandas に依存せず純 Python で統計検定を実行する。 α 多様性は Mann-Whitney U （2 群）または Kruskal-Wallis H （3 群以上）で検定し、Cliff's δ または η^2 の効果量を算出する。 β 多様性は距離行列全体を読み込み、群内/群間距離を分離し、擬似 PERMANOVA [Anderson, 2001]（199 パーミュテーション、固定シード）を実行する。分類学的差次解析は feature table と taxonomy を結合し、属レベルの fold change と絶対差を計算する。

4.2 Layer 2: EvalMediator と DecisionEngine

各完了ステップを表1の 8 軸で評価する。合成スコア $c_t = \sum_a w_a \cdot s_{t,a}$ はスコア行列のべき乗法 SVD で 3 主成分に圧縮される。

DecisionEngine は文献ベースのヒューリスティクスを確定的規則として符号化する： α (Willis, 2019： $p < 0.05 \wedge d > 0.5$ なら深掘り、 $p \geq 0.05$ ならスキップ)、 β (Anderson, 2001：有意なら betadisper 必須、非有意なら全スキップ)、分類学 (Gloor et al., 2017：高 fold change かつ低豊度なら組成バイアス警告)、品質 (McMurdie & Holmes, 2014：CV > 0.5 なら希薄化追加)。

Table 1: 評価軸、重み、計算方法。

軸	w	計算方法
statistical_significance	0.20	$\min(1, -\log_{10}(\min p)/4)$
biological_relevance	0.18	fold change + 既知菌属ボーナス
actionability	0.15	下流トリガー数
novelty	0.12	前ステップとの不整合
data_quality	0.10	スパース度・CV ペナルティ
effect_magnitude	0.10	$\max(\delta, F/3, \text{fc}/10)$
confidence	0.08	最小群サイズの階段関数
reproducibility	0.07	カテゴリ内一貫性

Table 2: データセットとシナリオ。「Diff.」 = 差次菌属 (fold change > 2×) の検出。

シナリオ	n	k	α	β	Diff.	データセット
MP-body	34	4	***	**	Y	Moving Pictures
MP-subject	34	2	ns	ns	Y	Moving Pictures
AT-transect	54	2	*	**	N	Atacama Soil
AT-vegetation	54	2	*	**	N	Atacama Soil
AT-depth	54	3	*	**	N	Atacama Soil
GN-IBD	87	2	ns	*	N	Gneiss (IBD)
FMT-treat	121	3	*	*	N	FMT Trial

4.3 Layer 3: LLM 補助

LLM (qwen2.5-coder、7B パラメータ、Ollama 経由でローカル実行) は 3 つの機能を担う：(1) 初期計画生成 (失敗時はドメイン知識フォールバック)、(2) 各ステップの Python コード生成 (最大 3 回リトライ、現時点で確定的代替なし——LLM 失敗時はステップが失敗・スキップ)、(3) リプランニング時の創造的調査仮説生成。マージ関数は Python 判断のスキップが LLM 提案の追加を上書きする。LLM 完全障害下では判断ループ (Layer 2) は正しく動作し続けるが、解析出力 (図・統計結果) は生成されない。このアーキテクチャ特性により、ワークフロー判断の正確性はコード生成品質とは独立に検証可能である。

5 評価

5.1 データセットとシナリオ

4 つの公開 16S rRNA アンプリコンデータセットから 7 つの解析シナリオを構築した (表2)。グループ変数を変えることで、強い多カテゴリシグナル (MP-body) から欠如シグナル (MP-subject)、不完全データ (Atacama 等、taxonomy なし) のスペクトルを生成した。

5.2 エキスパートプロトコル

21 の下流解析ステップそれぞれについて、公開されたベストプラクティスに基づくエキスパートプロトコルを定義した。このプロトコルはデータ依存だが規則確定的であり、所与のデータ特性に対してエキスパート判断は一意に決定される。DecisionEngine 実装とは独立に定義されたが、両者は同じドメイン知識を符号化しているため、一致は必要条件であるが十分

Table 3: 7 シナリオの判断精度（各 21 ステップ、計 147 判断）。

	MP-body	MP-subj.	AT-traus.	AT-veg.	AT-depth	GN-IBD	FMT
固定精度 (%)	95	62	52	57	52	52	52
適応精度 (%)	95	95	52	57	52	62	52
改善 (pp)	0	+33	0	0	0	+10	0
ノイズ (固定)	1	8	10	9	10	10	10
ノイズ (適応)	1	1	10	9	10	8	10
誤スキップ	0	0	0	0	0	0	0




Figure 2: 7 シナリオの判断精度、ノイズ削減、安全性。

条件ではない。

5.3 判断精度

表3に 7 シナリオの全ステップ比較を示す。

3 つのパターンが現れる。第一に、全データ特徴が存在する場合 (MP-body)、固定・適応とも 95% でエキスパートと一致する。第二に、有意シグナルが欠如する場合 (MP-subject)、固定パイプラインは 8 つの不要ステップを実行する (精度 62%) のに対し、エンジンは 7 つをスキップして 95% を達成する——33 パーセントポイントの改善。第三に、taxonomy が欠如する場合 (AT, GN, FMT)、差次豊度依存ステップを評価できず 52% のフロアとなる。全 147 判断を通じて偽陰性スキップ = 0。

5.4 統計検定の検証

純 Python 実装を scipy と 100 回のモンテカルロデータセットで比較した。検定統計量は数値的に同一。p 値の平均絶対誤差は Mann-Whitney 0.027、Kruskal-Wallis 0.014。有意性分類 ($p < 0.05$) の一致率は 99% および 100% であった。

5.5 生物学的結論の検証

Moving Pictures の 7 つの既知結論 [Bolyen et al., 2019] を全て確認した：body-site 群集区別 ($p = 6.7 \times 10^{-4}$, PERMANOVA $F = 112$)、Bacteroides の gut 優占 (56.4%)、body-site 効果の subject 効果に対する優位性 ($F = 112$ vs $F = 33$) 等。




Figure 3: 実行タイムライン。(A) スコアと成功/失敗。(B) リトライ回数。(C) エラー種別。(D) 累積成功率。

5.6 再現性

3 データセットに対して DecisionEngine を各 10 回実行した (計 30 回)。全回で判断と 8 軸スコアが完全同一であった。

5.7 実行フローと LLM 性能

Moving Pictures に対して qwen2.5-coder:7B で AI 駆動モードを完全実行し、30 ステップのタイムラインを取得した (図3)。

レジストリステップ (解析カタログから定義済み) は 54% の成功率 (7/13)、LLM 生成 Investigation は 6% (1/17) であった。成功 8 件のうち 5 件が初回成功、3 件がリトライで救済された (成功の 37.5%)。22 件は全リトライを消費して失敗し、支配的なエラーは NameError (60%) と KeyError (27%) であった。

エラー解決率の分析 (図4B) により、NameError はリトライで 17% 解決可能だが KeyError は 0%——LLM は単一のエラーメッセージからカラム名の相違を推論できない——ことが判明した。合成スコアはデータシグナル強度と相関し (図4A)、statistical_significance (0.52 vs 0.26) と effect_magnitude (0.53 vs 0.22) で最大の差が見られた。




Figure 4: (A) スコア分布。(B) エラー解決率。(C) リトライウォーターフォール。(D) ステップ別詳細。

5.8 LLM の役割分解

システム機能を 3 カテゴリに分解する：(1) 統計評価・判断——Layer 1-2 で完結、LLM 不関与、100% 再現可能；(2) コード生成——現在 LLM 依存 (54% 成功) だが、各ステップが固定仕様を持つためテンプレートベース生成で代替可能；(3) 創造的仮説生成——LLM を必要とする唯一の機能だが 7B モデルでの成功率は 6%。

6 制限事項

7B LLM の定義済みタスク成功率は 54%、新規調査は 6% に留まる。純 Python 統計実装は小サンプル ($n < 20$) で精度が低下する。判断木の閾値は文献慣行からの固定値であり最適化されていない。8 軸重みは手動設定で学習されていない。16S rRNA アンプリコンのみ対応。評価は 4 データセット 7 シナリオであり、縦断・症例対照等の追加デザインおよび独立した人間エキスパートとの比較による包括的検証が必要である。

7 考察

本研究の中心的知見は、マイクロバイオーम्ワークフローにおける解析判断の大部分が LLM の関与なしにデータから確定的に行えるということである。3 つの機能カテゴリのうち、LLM




Figure 5: (A) エラー種別分布。(B) リトライ有効性。(C) レジストリ vs Investigation 性能。

seq2pipe System Evaluation Summary

Component	Metric	Value	Assessment
DataInspector	scipy concordance (U/H stat)	Exact match	VALIDATED
	scipy concordance (p-value)	MAE=0.02, max=0.09	Acceptable
	Significance agreement	99-100%	VALIDATED
	Biological conclusions (Caporaso 2011)	7/7 confirmed	VALIDATED
DecisionEngine	Expert agreement (best case)	95%	Strong
	Expert agreement (mean, 7 scenarios)	66.7%	Moderate
	Wrong skips (false negatives)	0 / 147 decisions	SAFE
	Noise reduction (best case)	87.5%	Effective
	Reproducibility (30 runs)	100%	DETERMINISTIC
LLM (7B)	Registry step success	54% (7/13)	Marginal
	Investigation success	6% (1/17)	Inadequate
	Retry rescue rate	37.5% of successes	Partial
	Dominant error	NameError (18/30)	Fixable
	Template improvement	Import errors eliminated	Partial fix
Overall	Deterministic decisions	100% LLM-free	Core strength
	LLM-failure tolerance	System completes	Robust
	Bottleneck	7B code generation	Future work

Figure 6: システム評価サマリ。緑 = 検証済み/安全。赤 = 不十分。

を必要とするのは創造的仮説生成のみであり、それも 7B スケールでは信頼性に欠ける。このことは、自律的科学解析への道筋が主に LLM の大規模化ではなく、ドメイン特化型推論の監査可能で確定的な規則への形式化にあることを示唆する。

全 147 判断における偽陰性率ゼロは、精度値単独よりも強い安全保証である。不要な解析の実行は計算の浪費にすぎないが、必要な解析のスキップは発見の見逃しにつながる。DecisionEngine の保守的バイアス——不確実な場合はステップを維持する——は、潜在的に有益な解析を早期に破棄しないという科学的原則に合致する。

taxonomy 欠如データセットでの 52% のフロアは、適応的判断がデータの完全性に制約されることを示す。これは判断ロジックの限界ではなく入力限界であり、不足データ特徴を検出した際に追加の上流解析を推奨するデータ獲得判断の実装を動機付ける。




Figure 7: DecisionEngine の影響。(A) 精度改善。(B) ノイズ除去。(C) 全 147 判断で偽陰性=0。

8 結論

何を解析するか（確定的、LLM 不要）とどう実行するか（LLM 補助コード生成）をアーキテクチャ的に分離する閉ループマイクロバイーム適応解析システム SEQ2PIPE を提示した。4 公開データセット 7 シナリオでの評価により、確定的 DecisionEngine はエキスパート一致率最大 95% を偽陰性スキップ =0 かつ絶対的再現性で達成した。LLM はコード生成に不可欠であり（定義済みタスク 54% 成功）、システムの主要ボトルネックである：創造的調査の成功率は 6% に留まり、支配的エラー（NameError、KeyError）は推論能力ではなくコード合成能力の限界を反映する。

中心的設計原則はワークフロー判断はデータに基づくべきであり言語モデル出力に基づくべきではないということであり、同時に解析実行には現在 LLM が必要であることを認める。この分離により、判断の正確性はコード生成品質とは独立に検証可能となり、いずれかのコンポーネントの改善が他方に影響しないアーキテクチャ特性が得られる。

References

- Anderson, M. J. (2001). *Austral Ecology*, 26(1), 32–46.
- Bolyen, E., et al. (2019). *Nature Biotechnology*, 37(8), 852–857.
- Callahan, B. J., et al. (2016). *Nature Methods*, 13(7), 581–583.
- Di Tommaso, P., et al. (2017). *Nature Biotechnology*, 35(4), 316–319.
- Feurer, M., et al. (2015). *NeurIPS*, 28.
- Gloor, G. B., et al. (2017). *Frontiers in Microbiology*, 8, 2224.
- Hong, S., et al. (2024). *arXiv:2402.18679*.
- Köster, J. & Rahmann, S. (2012). *Bioinformatics*, 28(19), 2520–2522.
- McMurdie, P. J. & Holmes, S. (2014). *PLOS Comp. Biol.*, 10(4), e1003531.
- Thornton, C., et al. (2013). *KDD '13*, 847–855.

- Wasserstein, R. L., et al. (2019). *The American Statistician*, 73(sup1), 1–19.
- Willis, A. D. (2019). *Frontiers in Microbiology*, 10, 2407.
- Wilson, E. B. & Hilferty, M. M. (1931). *PNAS*, 17(12), 684–688.