

SEQ2PIPE: 解釈駆動型閉ループ適応的マイクロバイーム解析システム

佐藤翼 (Tsubasa Sato)

Independent Researcher

<https://github.com/Rhizobium-gits/seq2pipe>

2026 年 3 月

Abstract

現行のマイクロバイーム解析パイプラインは中間結果に関わらず固定されたステップ列を実行し、予想外のパターンや期待シグナルの欠如に対してエキスパートの介入を必要とする。本研究では、バイオインフォマティクスの反復的な解釈-判断-実行サイクルを計算的に再現する閉ループシステム SEQ2PIPE を提案する。本システムは 3 層で構成される: QIIME2 エクスポートを直接パースし純 Python で統計検定を実行する DataInspector、各ステップを 8 軸で定量評価する EvalMediator、文献に基づく決定木で解析計画を確定的に修正する DecisionEngine。ローカル大規模言語モデル (7B パラメータ) は各解析ステップの Python コード生成および創造的調査仮説の提案を担う。LLM はコード生成に不可欠であるが (現時点で確定的代替は未実装)、全てのワークフロー判断——どのステップをスキップ・追加・並べ替えるか——は DecisionEngine が LLM の関与なしに確定的に決定する。LLM 完全障害時、判断ループは正しく動作し続けるが、個々の解析ステップは実行できない。

4 つの公開データセットから導出した 12 シナリオ (252 の独立したステップ判断) で評価した。taxonomy データが利用可能な場合、DecisionEngine はエキスパート一致率を 61% から 95% に改善した (平均 +31 pp)。taxonomy が欠如する場合は固定パイプラインと同等の 52% にとどまった。偽陰性スキップは構造的にゼロである——エンジンはステップの除去のみを行い、計画に含まれない解析の追加は行わない。この保守的設計は安全性を保証するが、初期計画外の解析を発見する能力を制限する。重み不変性は 10,221 設定で検証し、判断は生の p 値と効果量のみ依存し、8 軸スコアの重みには依存しないことを証明した。確定性は 120 回の実行で確認した ($\sigma = 0$)。純 Python 統計検定は scipy との有意性分類一致率 99–100%、Moving Pictures の既知結論 7 件全てを確認した。主要ボトルネックは 7B モデルのコード生成 (レジストリ 47%、Investigation 25%) である。

1 はじめに

マイクロバイーム解析は複雑な多段階分野に成熟し、典型的なアンプリコンシーケンシング研究は品質管理、デノイジング [Callahan et al., 2016]、系統樹構築、 $\alpha \cdot \beta$ 多様性解析、分類学的分類、差次豊度検定、および下流の可視化を必要とする。

現行のパイプラインフレームワークは固定された有向非循環グラフ (DAG) としてワークフローを符号化する。QIIME2 [Bolyen et al., 2019] はプロベナンス追跡付きのプラグインアーキテクチャを提供するが、中間結果に基づく条件分岐はない。Snakemake [Köster & Rahmann, 2012] と Nextflow [Di Tommaso et al., 2017] は条件付き規則をサポートするが、条件はユーザーが事前に指定する必要がある、統計的有意性や効果量を検査してワークフロー




Figure 1: 概念比較。(a) 静的パイプラインは結果に関わらず全ステップを固定順で実行。(b) SEQ2PIPE は各ステップの出力を評価し、判断ノード（黄色菱形）で不要なフォローアップをスキップ（赤破線）または対象解析を追加（青）する。

を変更しない。その結果、PERMANOVA が $p = 0.81$ を返しても下流の β 多様性フォローアップは実行され、逆に *Bacteroides* の 324 倍濃縮のような予想外の発見は自動的なフォローアップを引き起こさない。

経験豊富なバイオインフォマティシャンは異なる方法で作業する：解釈、仮説形成、解析選択、洗練の閉ループで、安定した内部整合的な解釈に到達するまで継続する。既存のパイプラインシステムはこの挙動を計算的に再現しない。

本研究では、この推論ループを 3 つの確定的層とオプションの LLM に分離するシステム SEQ2PIPE を導入する。主要な貢献は以下の通りである：

1. データ検査、評価・判断（ともに確定的）、コード生成（LLM 補助）を分離し、LLM 障害耐性を持つ 3 層アーキテクチャ
2. Anderson (2001)、Willis (2019)、Gloor et al. (2017)、McMurdie & Holmes (2014) の解析ヒューリスティクスを確定的決定木として符号化する文献基盤の DecisionEngine
3. 4 公開データセット・7 シナリオでの定量的評価（エキスパート一致率 95%、偽陰性スキップ = 0、再現性 100%）

2 関連研究

2.1 静的パイプラインフレームワーク

QIIME2 [Bolyen et al., 2019] はプラグインベースのモジュール性とプロベナンス追跡を提供するが、中間結果に基づく動的なワークフロー変更はない。Snakemake [Köster & Rahmann, 2012] と Nextflow [Di Tommaso et al., 2017] は汎用ワークフロー管理を提供するが、条件は実行前にユーザーが定義する必要がある。

2.2 自動解析システム

Auto-WEKA [Thornton et al., 2013] と Auto-sklearn [Feurer et al., 2015] はベイズ最適化によるモデル選択を自動化するが、固定の目的関数を持つ教師あり学習を対象とする。マイクロ

バイオーム解析は本質的にオープンエンドであり、「正しい」次のステップは現在のステップの発見に依存する。

2.3 LLM ベースの解析エージェント

Data Interpreter [Hong et al., 2024] や ChatGPT Advanced Data Analysis は自然言語プロンプトからコードを生成・実行する。これらのシステムは LLM に判断とコード生成の双方を完全に依存しており、(a) 中間結果のドメイン特化型定量評価、(b) 文献基盤の判断ヒューリスティクス、(c) LLM 障害時の確定的フォールバックが欠如している。SEQ2PIPE はアーキテクチャ分離によりこの 3 つのギャップに対処する。

3 概念的フレームワーク：自動と自律の区別

自動 (*automated*) と自律 (*autonomous*) の区別は本研究の中心的問題である。

3.1 パイプライン知性の 3 段階

定義 1 (静的パイプライン (Level 0)). 実行計画 P が実行前に固定。 $P_{t+1} = P_t \setminus \{s_t\}$ が常に成立し、結果に関わらず変更されない。

定義 2 (自動パイプライン (Level 1)). 事前定義の条件規則を持つ： $P_{t+1} = f(P_t, \phi)$ 。条件 ϕ は実行前に定義され、中間結果の内容に依存しない (例: 「ファイルが存在すればステップを実行」)。

定義 3 (自律パイプライン (Level 2)). 中間結果の内容を検査し、文脈依存の判断を行う： $H_{t+1} = H_t \cup \text{interpret}(r_t, D)$ 、 $P_{t+1} = \text{decide}(H_{t+1}, P_t, D)$ 。interpret は実データから統計的特徴 (有意性、効果量、*fold change*) を計算し、decide はそれらの特徴に基づいて計画を修正する。Level 1 との本質的差異は、データそのものが分岐を決定することである。

3.2 seq2pipe の位置づけとその限界

SEQ2PIPE は Level 2 で動作するが、以下の限定がある：

- **知覚において自律的**：DataInspector が実行時にデータから統計的特徴ベクトル $\mathbf{x} = (p_\alpha, d_\alpha, p_\beta, \text{ratio}, \text{fc}_{\max}, \dots)$ を計算する。同じコードが異なるデータで異なるベクトルを生成する。
- **判断において自律的**：DecisionEngine はこの実行時計算された特徴に基づいて分岐する。分岐構造 (decision graph) 自体は固定だが、グラフ内の経路はデータが決定する。
- **規則進化において非自律的**：判断規則は実行内で変化しない。人間なら「rarefaction で artifact が確認された $\rightarrow$ alpha 全体の信頼性を再評価」と推論するが、SEQ2PIPE はしない。これは今後の課題である。

3.3 判断グラフ

意思決定プロセスを有向非循環グラフ $G = (V, E)$ として形式化する (図??)。各内部ノード $v \in V$ は特徴ベクトル $\mathbf{x}$ 上の述語を検査する： $v : \mathbf{x} \mapsto \{\text{TRUE}, \text{FALSE}\}$ 。葉ノードは行動：SKIP(s)、ADD(s)、KEEP(s)。




Figure 2: 3 層アーキテクチャ。Layer 1-2 は確定的で LLM 非依存。Layer 3 はオプション。

判断関数全体は： $\text{decide}(H_t, P_t, D) = \{a_s \mid s \in P_t, a_s = G(\mathbf{x}(H_t, D), s)\}$

自律性の根拠：(1) 述語が検査する特徴は実行時に計算される（事前指定でない）。(2) 特徴ベクトルは各ステップ後に更新される（発見の蓄積）。(3) 4 ステップごとに全データを再検査しグラフを再走査する（閉ループ再評価）。

限界：判断規則自体は静的であり、実行内で進化しない。完全自律システムは蓄積経験に基づいて G 自体を更新する——これは将来の研究方向である。

4 システムアーキテクチャ

アーキテクチャ（図2）は厳格な分離を強制する：Layer 1-2 は確定的で LLM 不要、Layer 3 は確率的で代替可能。

4.1 Layer 1: DataInspector

DataInspector は QIIME2 エクスポート TSV ファイルを直接パースし、`scipy`・`numpy`・`pandas` に依存せず純 Python で統計検定を実行する。 α 多様性は Mann-Whitney U （2 群）または Kruskal-Wallis H （3 群以上）で検定し、Cliff's δ または η^2 の効果量を算出する。 β 多様性は距離行列全体を読み込み、群内/群間距離を分離し、擬似 PERMANOVA [Anderson, 2001]（199 パーミュテーション、固定シード）を実行する。分類学的差次解析は feature table と taxonomy を結合し、属レベルの fold change と絶対差を計算する。

4.2 Layer 2: EvalMediator と DecisionEngine

各完了ステップを表1の 8 軸で評価する。合成スコア $c_t = \sum_a w_a \cdot s_{t,a}$ はスコア行列のべき乗法 SVD で 3 主成分に圧縮される。

DecisionEngine は文献ベースのヒューリスティクスを確定的規則として符号化する： α (Willis, 2019： $p < 0.05 \wedge d > 0.5$ なら深掘り、 $p \geq 0.05$ ならスキップ)、 β (Anderson, 2001：有意なら betadisper 必須、非有意なら全スキップ)、分類学 (Gloor et al., 2017：高 fold change かつ低豊度なら組成バイアス警告)、品質 (McMurdie & Holmes, 2014：CV > 0.5 なら希薄化追加)。

Table 1: 評価軸、重み、計算方法。

軸	w	計算方法
statistical_significance	0.20	$\min(1, -\log_{10}(\min p)/4)$
biological_relevance	0.18	fold change + 既知菌属ボーナス
actionability	0.15	下流トリガー数
novelty	0.12	前ステップとの不整合
data_quality	0.10	スパース度・CV ペナルティ
effect_magnitude	0.10	$\max(\delta, F/3, \text{fc}/10)$
confidence	0.08	最小群サイズの階段関数
reproducibility	0.07	カテゴリ内一貫性

4.3 Layer 3: LLM 補助

LLM (qwen2.5-coder、7B パラメータ、Ollama 経由でローカル実行) は 3 つの機能を担う：(1) 初期計画生成 (失敗時はドメイン知識フォールバック)、(2) 各ステップの Python コード生成 (最大 3 回リトライ、**現時点で確定的代替なし**——LLM 失敗時はステップが失敗・スキップ)、(3) リプランニング時の創造的調査仮説生成。マージ関数は Python 判断のスキップが LLM 提案の追加を上書きする。LLM 完全障害下では判断ループ (Layer 2) は正しく動作し続けるが、解析出力 (図・統計結果) は生成されない。このアーキテクチャ特性により、ワークフロー判断の正確性はコード生成品質とは独立に検証可能である。

5 評価

評価は 3 つの問いに構造化される：(1) DecisionEngine は正しい判断をするか？(2) その判断はハイパーパラメータ摂動に対して頑健か？(3) LLM の実際の貢献とボトルネックは何か？

5.1 実験設計

データセット。 QIIME2 ドキュメントサーバーから入手可能な 4 つの公開 16S rRNA データセット (Moving Pictures 34 サンプル、Atacama Soil 54、Gneiss IBD 87、FMT Trial 121) を使用した。各データセット内のグループ変数を変えることで 12 の解析シナリオを構築した。

エキスパートプロトコル。 21 の下流解析ステップそれぞれについて、データ特性ベクトルに対してエキスパート判断が一意に決まる文献ベースのプロトコル [Anderson, 2001, Willis, 2019, Gloor et al., 2017, McMurdie & Holmes, 2014] を定義した。DecisionEngine 実装とは独立に定義された。

評価レベル。 独立判断 (ユニークなシナリオ $\times$ ステップ) と再現性検証 (同一条件の反復実行) を区別する：

1. **実データ精度**：12 シナリオ $\times$ 21 ステップ = **252 の独立判断** (確定性検証のため 10 回反復)。21 中 7 ステップは「常に実行」で 33% のベースライン精度を提供し、エンジンの実効寄与は残り 14 の判断対象ステップにある。
2. **合成データ汎化性**：10,000 ベクトル $\times$ 21 ステップ = 210,000 判断。エキスパートプロトコルとエンジンが同じ規則を符号化しているため、高い一致は独立検証ではなく整合性チェックである。

Table 2: 判断精度：12 シナリオ、252 独立判断（10 回反復、std = 0）。21 中 7 ステップは常時実行（ベースライン 33%）。

	<i>MP-body</i>	<i>MP-subj.</i>	<i>MP-year</i>	<i>MP-abx</i>	<i>AT-trans.</i>	<i>AT-veg.</i>	<i>AT-depth</i>	<i>GN-IBD</i>	<i>GN-sex</i>	<i>FMT-treat</i>	<i>FMT-type</i>	<i>FMT-gend.</i>
<i>n</i>	34	34	34	34	54	54	54	87	87	121	121	121
固定 (%)	95	62	71	71	52	57	52	52	38	52	52	33
適応	95	95	95	95	52	57	52	62	86	52	52	81
Δ (pp)	0	+33	+24	+24	0	0	0	+10	+48	0	0	+48
誤スキップ	0	0	0	0	0	0	0	0	0	0	0	0

3. 重み不変性：10,221 設定。精度ではなく、重みが判断に不活性であることの証明。

5.2 実データ判断精度

3 つのパターンが現れる。第一に、全シグナルが有意な場合、エンジンは 95% で過度な最適化なし。第二に、群間差欠如時に最大 +48 pp の改善。第三に、taxonomy 欠如時は 52% フロア。全 2,520 判断で偽陰性 = 0。

5.3 汎化性：10,000 合成シナリオ

注意。 エキスパートプロトコルと DecisionEngine は同じドメイン規則を符号化しているため、この実験での高い一致は独立検証ではなく整合性チェックである。エンジンのロジックがデータ特徴空間をエッジケースなしにカバーすることを確認するが、規則自体が最適であることの証明にはならない。

結果：平均精度 70.6%±12.6%。75.5% 改善、24.5% 同等、0% 悪化。「静的より悪くならない」性質はエンジンがステップの除去のみを行うことに起因する。

5.4 重み不変性

10,221 の重み設定（感度分析 8+ グリッド 213+ ランダム 10,000）が全シナリオで同一判断を生成。6.4 時間の網羅的実行（2,520,000 回）で $\sigma = 0$ 。

定理（重み不変性）：任意の $\mathbf{w}_1, \mathbf{w}_2 \in \Delta^7$ と固定 D に対し $\text{decide}(\mathbf{w}_1, D) = \text{decide}(\mathbf{w}_2, D)$ 。

DecisionEngine は生の p 値と効果量のみを参照し、合成スコアや重みを一切参照しないことがソースコード検査で確認された。重み最適化は不要。

5.5 検証

統計検定精度。 scipy 比較 100 試行：統計量同一、 p 値 MAE 0.027/0.014、有意性一致 99/100%。

生物学的結論。 Caporaso 結論 7/7 確認 ($p = 6.7 \times 10^{-4}$, $F = 112$, Bacteroides 56.4%)。

再現性。 120 回実行で判断・スコア完全同一。



Figure 3: 実データ評価（12 シナリオ、2,520 判断）。

5.6 LLM 性能分析

27 ステップ実行（39 分）：レジストリ 47%、Investigation 25%、全体 41%。支配的エラー NameError（60%、解決率 17%）、KeyError（27%、0%）。成功はシグナル強度と相関（significance 0.52 vs 0.26）。

5.7 LLM 機能分解

6 制限事項

7B LLM のコード生成成功率は 47%（レジストリ）/25%（Investigation）に留まる。純 Python 統計実装は小サンプル（ $n < 20$ ）で精度が低下する。判断木の閾値は文献慣行からの固定値であるが、重み不変性定理（5.4節）により閾値の影響は p 値・効果量レベルに限定され、重みの影響は皆無であることが証明された。16S rRNA アンプリコンのみ対応。エキスパートプロトコルは文献ベースで著者が定義しており、独立した人間エキスパートとの比較による検証が今後必要である。

7 考察

本研究の中心的知見は、マイクロバイームワークフローにおける解析判断の大部分が LLM の関与なしにデータから確定的に行えるということである。2,732,520 件の判断評価を通じて、DecisionEngine は偽陰性率ゼロを維持しつつ平均 +16.8 pp の改善を達成した。さらに、重み不変性定理により判断がハイパーパラメータ設定に対して完全に頑健であることが数学的に




Figure 4: 合成評価 (10,000 シナリオ、210,000 判断)。

証明された。

偽陰性率ゼロは精度値単独よりも強い安全保証を提供する。不要な解析の実行（偽陽性）は計算の浪費にすぎないが、必要な解析のスキップ（偽陰性）は科学的発見の見逃しにつながる。DecisionEngine の保守的バイアス——不確実な場合はステップを維持する——は、潜在的に有益な解析を早期に破棄しないという科学的原則に合致する。10,000 合成シナリオでゼロケースの悪化が確認されたことは、この保守性が体系的であることを示す。

taxonomy 欠如データセットでの 52% のフロアは、適応的判断がデータの完全性に制約されることを示す。これは判断ロジックの限界ではなく入力の限界であり、不足データ特徴を検出した際に追加の上流解析を推奨するデータ獲得判断の実装を動機付ける。

8 結論

何を解析するか（確定的、LLM 不要）とどう実行するか（LLM 補助コード生成）をアーキテクチャ的に分離する閉ループマイクロバイーム適応解析システム SEQ2PIPE を提示した。

12 シナリオ 252 の独立判断で評価した結果、taxonomy データ利用可能時に DecisionEngine はエキスパート一致率を 61% から 95% に改善した（平均 +31 pp）。taxonomy 欠如時は固定パイプラインと同等の 52% にとどまった。偽陰性スキップは構造的にゼロであるが、これは skip のみを行う保守的設計の結果であり、伝統的な意味での高精度の証拠ではない。エンジンの主要な価値はノイズ削減——データが支持しない解析の正確な除去——にある。

LLM はコード生成に不可欠であり（47% 成功）、ボトルネックである。8 軸重みは 10,221 設定で判断に不変であることが証明された。エキスパートプロトコルがエンジンと同じ規則




Figure 5: 実行タイムライン。

を符号化している点、Nextflow/Snakemake の未統合、判断規則の実行内非進化は正直な限界である。これらの限界にもかかわらず、確定的推論と確率的コード生成のアーキテクチャ分離は、監査可能で再現可能な適応解析システム構築のテンプレートを提供する。

References

- Anderson, M. J. (2001). *Austral Ecology*, 26(1), 32–46.
- Bolyen, E., et al. (2019). *Nature Biotechnology*, 37(8), 852–857.
- Callahan, B. J., et al. (2016). *Nature Methods*, 13(7), 581–583.
- Di Tommaso, P., et al. (2017). *Nature Biotechnology*, 35(4), 316–319.
- Feurer, M., et al. (2015). *NeurIPS*, 28.
- Gloor, G. B., et al. (2017). *Frontiers in Microbiology*, 8, 2224.
- Hong, S., et al. (2024). *arXiv:2402.18679*.




Figure 6: シグナル強度と成功の関係。

Köster, J. & Rahmann, S. (2012). *Bioinformatics*, 28(19), 2520–2522.

McMurdie, P. J. & Holmes, S. (2014). *PLOS Comp. Biol.*, 10(4), e1003531.

Thornton, C., et al. (2013). *KDD '13*, 847–855.

Wasserstein, R. L., et al. (2019). *The American Statistician*, 73(sup1), 1–19.

Willis, A. D. (2019). *Frontiers in Microbiology*, 10, 2407.

Wilson, E. B. & Hilferty, M. M. (1931). *PNAS*, 17(12), 684–688.




Figure 7: エラー分析。

Table 3: 機能別 LLM 依存性。

機能	LLM?	成功率	代替?	根拠
統計評価	No	100%	N/A	scipy 一致 99-100%
判断	No	100%	N/A	270 万判断、誤り 0
初期計画	Yes*	—	Yes	フォールバック存在
コード生成	Yes	47%	部分的	テンプレートで import 修正のみ
エラー修復	Yes	37.5%	No	3/8 成功を救済
仮説生成	Yes	25%	No	代替不可能な唯一の LLM 機能

seq2pipe System Evaluation Summary

Component	Metric	Value	Assessment
DataInspector	scipy concordance (U/H stat)	Exact match	VALIDATED
	scipy concordance (p-value)	MAE=0.02, max=0.09	Acceptable
	Significance agreement	99-100%	VALIDATED
	Biological conclusions (Caporaso 2011)	7/7 confirmed	VALIDATED
DecisionEngine	Expert agreement (best case)	95%	Strong
	Expert agreement (mean, 7 scenarios)	66.7%	Moderate
	Wrong skips (false negatives)	0 / 147 decisions	SAFE
	Noise reduction (best case)	87.5%	Effective
	Reproducibility (30 runs)	100%	DETERMINISTIC
LLM (7B)	Registry step success	54% (7/13)	Marginal
	Investigation success	6% (1/17)	Inadequate
	Retry rescue rate	37.5% of successes	Partial
	Dominant error	NameError (18/30)	Fixable
	Template improvement	Import errors eliminated	Partial fix
Overall	Deterministic decisions	100% LLM-free	Core strength
	LLM-failure tolerance	System completes	Robust
	Bottleneck	7B code generation	Future work

Figure 8: システム評価サマリ。